

RAPPORT DE PROJET STATISTIQUE

Élèves 2A

Titre choisi pour mon rapport en Quarto

Étudiants :

Arthur DELETANG
Maëlys D'HALLUIN
Clémence PINSARD

Tuteur :

Imad Hamri

Résumé

La détection précoce des talents sportifs et la compréhension de la trajectoire des athlètes d'élite constituent des enjeux majeurs pour les fédérations sportives internationales. Cette étude s'intéresse à la relation entre l'âge et la performance en athlétisme, en cherchant à identifier l'âge au pic de performance selon les disciplines et le sexe. Mieux comprendre cette dynamique permet non seulement d'optimiser la planification des carrières sportives, mais aussi d'améliorer les stratégies de détection et d'accompagnement des jeunes athlètes. L'analyse s'appuie sur les données de World Athletics couvrant la période 1985–2024, recensant les 100 meilleures performances annuelles mondiales par discipline et par sexe. Deux modèles non linéaires sont mobilisés : le modèle de Moore (1975) et le modèle IMAP (Berthelot et al., 2019), appliqués à trois familles de disciplines — sprint, lancers et endurance. Cette étude permet de comparer les dynamiques de progression et de déclin entre disciplines et entre sexes, et ainsi contribuer à une meilleure connaissance du vieillissement athlétique.

Abstract

Early talent detection and understanding the career trajectories of elite athletes are key challenges for international sports federations. This study examines the relationship between age and performance in athletics, aiming to identify peak performance age across disciplines and sexes. A deeper understanding of this dynamic can help optimize career planning and improve strategies for identifying and supporting young athletes. The analysis draws on World Athletics data spanning 1985–2024, covering the top 100 annual performances worldwide per discipline and sex. Two nonlinear models are applied: the Moore model (1975) and the IMAP model (Berthelot et al., 2019), across three discipline families — sprints, throws, and endurance. This study allows us to compare the dynamics of progression and decline between disciplines and between sexes, and thus contribute to a better understanding of athletic aging.

Mots-clés

Table des matières

Résumé	1
Abstract	1
Mots-clés	1
Introduction	3
Contexte et enjeux	3
Objectif de l'étude	3
Questions de recherches et trajectoires attendues	3
1 Présentation des données	5
1.1 Préparation et nettoyage des données	5
1.2 Variables d'intérêt	6
2 Étude 1 : Statistiques descriptives et analyse inférentielle	7
2.1 Méthodologie	7
2.2 Résultats descriptifs et indicateurs de position	7
2.3 Étude de la distribution et vérification de la normalité	8
2.4 Analyse inférentielle : Influence du sexe et de la discipline	10
2.5 Discussion	11
3 Etude 2 : Modèles	12
3.1 Méthodologie	12
3.1.1 Modèle de Moore (1975)	12
3.1.2 Modèle IMAP (2019)	13
3.1.3 Méthode générale	14
3.2 Résultats	19
Résultats du modèle IMAP	19
3.3 Discussion	20
4 Discussion générale	21
Conclusion	22
Remerciements	23
Références	24
Annexes	25
4.1 Compléments de l'analyse de distribution	25
4.1.1 Distributions des athlètes féminines	25
4.1.2 Analyse de la normalité (QQ-Plots)	25

Introduction

Contexte et enjeux

La détection précoce des talents sportifs constitue un enjeu majeur pour les fédérations internationales d'athlétisme. Si la question de l'identification des jeunes athlètes prometteurs semble intuitive, elle se révèle en réalité bien plus complexe : les performances exceptionnelles observées à l'adolescence ne garantissent pas nécessairement la réussite au plus haut niveau à l'âge adulte. Ce constat soulève une problématique centrale : comment identifier, parmi les jeunes athlètes performants, ceux qui parviendront à maintenir, voire améliorer leur niveau dans les années suivantes ?

Cette question s'inscrit dans un contexte scientifique où la relation entre l'âge et la performance sportive a fait l'objet de nombreuses recherches. Depuis les travaux pionniers de Moore en 1975, qui proposa le premier modèle mathématique de cette relation, la communauté scientifique n'a cessé d'approfondir la compréhension de cette dynamique. Plus récemment, Berthelot et ses collaborateurs ont développé en 2019 le modèle IMAP (Integrative Model of Age-Performance), fondé sur des mécanismes biologiques cellulaires, offrant ainsi une nouvelle perspective pour modéliser l'évolution des capacités physiques tout au long de la vie.

Notre étude s'appuie sur une base de données internationale fournie par World Athletics, couvrant la période 2000-2024 et recensant les 100 meilleures performances annuelles, pour chaque sexe, dans chaque discipline athlétique. Ce corpus, portant sur plusieurs dizaines de milliers de performances au plus haut niveau mondial, permet d'analyser finement la trajectoire des athlètes d'élite à travers différentes disciplines.

Objectif de l'étude

L'objectif principal de ce projet est d'analyser la relation entre l'âge et la performance en athlétisme. Plus spécifiquement, nous cherchons à comprendre comment évoluent les performances athlétiques au fil du temps et à déterminer l'âge auquel les athlètes atteignent leur pic de performance.

Contrairement aux approches basées uniquement sur l'âge moyen des athlètes, qui peuvent être biaisées par les différences d'âge de début et de fin de carrière selon les pays ou les disciplines, notre étude se concentre sur l'identification de l'âge au pic de performance. Cette approche permet de mieux comprendre la dynamique temporelle de la performance sportive, caractérisée par une phase de croissance progressive des capacités, suivie d'un plateau puis d'un déclin lié au vieillissement.

Questions de recherches et trajectoires attendues

L'analyse de nos données vise à répondre à plusieurs interrogations fondamentales sur la dynamique de la performance athlétique. La littérature scientifique nous guide dans la formulation de nos attentes quant aux résultats escomptés.

Tout d'abord, nous cherchons à caractériser la variabilité de l'âge au pic de performance selon les disciplines. Les travaux d'Allen et Hopkins[?] ont établi une relation claire entre la durée de l'épreuve et l'âge optimal de performance : dans les épreuves de puissance explosive et de sprint, l'âge au pic décroît avec la durée de l'effort, allant d'environ 27 ans pour les lancers à 20 ans pour les sprints courts en natation. À l'inverse, pour les épreuves d'endurance, l'âge au pic augmente avec la durée, s'échelonnant d'environ 20 ans pour les épreuves courtes à près de 39 ans pour l'ultra-endurance cycliste. Cette tendance s'explique par les différences dans les systèmes énergétiques sollicités et le temps nécessaire au développement complet des capacités aérobies. Nous nous attendons donc à observer dans nos données un âge au pic plus précoce pour les épreuves de sprint et de saut, et plus tardif pour les disciplines d'endurance comme le demi-fond et le fond.

La question des différences entre sexes mérite également une attention particulière. Bien que plusieurs études, notamment celle d'Allen et Hopkins[?], rapportent peu de différences entre hommes et femmes dans l'âge au pic de performance pour les épreuves explosives et d'endurance, d'autres travaux suggèrent une distinction : l'analyse des Jeux Olympiques 2020 [?] révèle que l'âge moyen des athlètes masculins est d'un an supérieur à celui des femmes. De plus, des études sur le vieillissement athlétique indiquent que le déclin de performance avec l'âge pourrait être plus marqué chez les femmes que chez les hommes dans certaines disciplines, particulièrement en sprint, tandis que cette différence s'atténue dans les épreuves d'endurance longue. Nos analyses chercheront à confirmer ou infirmer ces tendances sur notre échantillon d'athlètes.

Enfin, la dynamique temporelle de la performance nous intéresse particulièrement. La relation âge-performance suit typiquement une forme asymétrique en U inversé : une phase de croissance progressive durant l'enfance et l'adolescence, un plateau lors du pic de performance à l'âge adulte, puis un déclin dont la vitesse s'accélère après 70 ans. Carter [?] décrit cette asymétrie comme une caractéristique fondamentale du vieillissement humain. La phase de croissance et la phase de déclin ne sont pas symétriques, et cette asymétrie pourrait varier selon les disciplines. Les épreuves de puissance, qui dépendent fortement des fibres musculaires rapides, connaissent un déclin plus précoce et prononcé que les épreuves d'endurance, où la perte de capacité aérobie est plus progressive. Nous explorerons donc la vitesse de progression en début de carrière et la vitesse de déclin après le pic, en comparant ces dynamiques entre disciplines et entre sexes.

1 Présentation des données

Notre étude s'appuie sur une base de données issue de World Athletics, la fédération sportive internationale chargée de régir les fédérations nationales d'athlétisme et d'organiser les compétitions internationales mondiales ¹. Cette base recense, pour chaque discipline et chaque année entre 1985 et 2024, les 100 meilleures performances mondiales réalisées lors de compétitions officielles.

Les données comportent plusieurs variables clés : l'identifiant de l'athlète, son âge au moment de la performance, son sexe, sa nationalité, la discipline pratiquée, la performance brute (temps, distance ou hauteur selon la discipline) et le ResultScore. Ce dernier, développé par World Athletics, constitue une métrique normalisée permettant de comparer les performances entre disciplines différentes en s'appuyant sur des paramètres définis par des experts du domaine.

La base couvre l'ensemble des disciplines olympiques en athlétisme : courses (sprint, demi-fond, fond, haies, relais), sauts (hauteur, longueur, triple saut, perche), lancers (poids, disque, javelot, marteau) et épreuves combinées (décathlon, heptathlon). Cette diversité permet d'analyser finement les spécificités de chaque famille de disciplines.

Il convient toutefois de noter certaines limites structurelles : un déséquilibre dans la répartition des athlètes par âge, avec une sous-représentation des athlètes de plus de 35 ans, ainsi qu'une possible hétérogénéité dans la qualité de l'enregistrement des données selon les périodes et les pays. Ces biais potentiels seront pris en compte dans notre analyse et discutés dans l'interprétation des résultats.

1.1 Préparation et nettoyage des données

Le passage des données brutes à un échantillon exploitable a nécessité un protocole de nettoyage, articulé autour de quatre étapes clés :

- **Calcul de l'âge et nettoyage initial** : Les entrées ne disposant pas de performance numérique exploitable ou d'une date de naissance valide ont été écartées. L'âge de chaque athlète a été calculé par la différence entre l'année de la performance (*season*) et son année de naissance.

Une limite méthodologique inhérente à la base de données doit être soulignée : la date exacte de la performance n'étant pas disponible, l'âge au pic a été estimé par la différence entre l'année de la compétition et l'année de naissance de l'athlète.

- **Identification des carrières terminées** : Afin d'éviter le biais de troncature (inclure un athlète n'ayant pas encore atteint son pic), nous avons restreint l'étude aux athlètes retraités. Un seuil de "retraite" a été fixé à l'année 2022 : tout athlète ayant réalisé une performance après cette date a été considéré comme actif et exclu de l'analyse.
- **Sélection de la meilleure performance annuelle** : Pour chaque athlète, à chaque âge et dans chaque discipline, nous n'avons conservé que la meilleure performance annuelle. Cette étape permet d'éliminer les variations de forme intra-saisonnières. Les disciplines ont ensuite été regroupées en trois familles majeures : **Sprint**, **Lancers** et **Endurance**.
- **Filtrage par expérience et équilibrage (Top 32)** : Pour garantir que l'âge au pic observé soit représentatif d'une trajectoire complète, seuls les athlètes ayant au moins **5 années de performances** enregistrées dans une même discipline ont été retenus. Enfin, pour corriger les disparités d'effectifs entre les sexes, nous avons procédé à un échantillonnage équilibré en sélectionnant le **Top 32** des meilleurs athlètes par discipline et par sexe, seuil défini par l'effectif le plus restreint du jeu de données (heptathlon).

¹https://fr.wikipedia.org/wiki/World_Athletics

1.2 Variables d'intérêt

L'analyse repose sur un ensemble de variables structurées pour répondre à la problématique de l'évolution de la performance :

- **Age_Pic_Obs** : L'âge auquel l'athlète a réalisé son record personnel absolu au cours de sa carrière. Il s'agit de notre variable dépendante centrale.
- **Sex** : Pour comparer les performances entre les femmes et les hommes.
- **Famille** : Regroupement des disciplines par filières énergétiques (Sprint, Lancers, Endurance).
- **Discipline** : Pour observer les ressemblances et différences entre les 24 disciplines en athlétisme.
- **meilleure_perf_km_par_h** : Conversion de la performance en kilomètre par heure afin d'avoir des valeurs positives à maximiser dans nos modèles.

2 Étude 1 : Statistiques descriptives et analyse inférentielle

Dans l'optique de mieux comprendre la structure de l'échantillon d'élite et d'en obtenir une vue d'ensemble, les caractéristiques de l'âge au pic observé sont examinées en premier lieu. Cette analyse préliminaire permet d'identifier des tendances majeures et de justifier le choix des modélisations non linéaires (Moore et IMAP) qui suivront.

2.1 Méthodologie

La démarche analytique est structurée en trois phases complémentaires. Une **analyse descriptive** globale est d'abord menée pour identifier les indicateurs de position (médiane, quartiles) selon le sexe et la discipline. Ensuite, la distribution des données est soumise à un **test de normalité** (Shapiro-Wilk) afin de valider le cadre statistique. Enfin, une **analyse inférentielle** est déployée pour tester statistiquement l'influence du sexe et de la spécialité athlétique sur l'âge de performance.

2.2 Résultats descriptifs et indicateurs de position

Afin de cerner les principales caractéristiques de la population étudiée, une analyse descriptive a été menée sur l'ensemble des disciplines. L'examen de la distribution globale (Figure 1) permet d'observer que la majorité des records personnels sont enregistrés dans une fenêtre comprise entre 22 et 28 ans pour les deux sexes. **On note cependant une répartition distincte selon le genre : les hommes sont davantage représentés entre 21 et 24 ans, tandis que la tendance s'inverse par la suite. À partir de 26 ans, on observe une proportion plus importante de femmes atteignant leur âge au pic.**




Figure 1: Distribution de l'âge au pic

Les indicateurs de position associés à cette distribution sont détaillés dans le tableau ci-dessous :

Table 1: Résumé statistique de l'âge au pic observé selon le sexe

Sexe	Eff.	Min	Q1	Moyenne $\pm$ SD	Médiane	Q3	Max
Hommes	672	18	23	25.72 $\pm$ 3.74	25	28	46
Femmes	672	17	24	26.25 $\pm$ 3.60	26	29	40

Une différence d'un an est observée sur l'âge médian, s'établissant à 25 ans chez les hommes contre 26 ans chez les femmes. La répartition par familles de disciplines (Figure 2) montre également des variations de maturité sensibles selon les spécialités.




Figure 2: Âges au pic observés selon les familles de disciplines et le sexe

Le groupe **Sprint** se distingue par la maturité la plus précoce, avec des médianes basses et une distribution resserrée. À l'inverse, le **Marathon** et les **Lancers** affichent les médianes les plus élevées.

On observe des structures de distribution spécifiques selon les familles :

- **Proximité entre sexes** : En **Haies**, en **Sauts** et dans les **Épreuves combinées**, les médianes et les quartiles sont quasiment alignés entre les hommes et les femmes.
- **Dispersion** : La famille **Lancers** et le **Marathon** montrent des distributions supérieures très étirées, signalant une plus grande variabilité de l'âge au pic.
- **Valeurs extrêmes** : Les **Lancers** et le **5000 - 10000** présentent de nombreux points isolés vers le haut, particulièrement chez les hommes, contrairement aux épreuves combinées ou aux Haies.

2.3 Étude de la distribution et vérification de la normalité

Avant de procéder aux tests d'inférence, il est indispensable d'étudier la forme de la distribution de notre variable d'intérêt : l'âge au pic observé. Cette étape permet de vérifier si les données suivent une loi normale, condition *sine qua non* pour l'utilisation de tests paramétriques classiques.

Analyse visuelle par les histogrammes

L'examen des histogrammes permet d'observer la répartition réelle des athlètes par classe d'âge. La Figure 3 présente cette distribution pour les athlètes masculins, segmentée par Famille de disciplines.




Figure 3: Distributions de l'âge au pic de performance (Athlètes masculins)

L'observation de la Figure 3 révèle des profils variés :

- Certaines familles, comme le **Sprint**, montrent une concentration très marquée sur des âges précoces avec une chute rapide de l'effectif.
- D'autres, comme les **Lancers**, présentent une distribution plus étalée, suggérant une plus grande hétérogénéité des âges de performance.
- De manière générale, on observe une “queue” de distribution vers la droite (asymétrie positive), indiquant que si l'accès au haut niveau est limité avant 20 ans, le maintien de la performance peut se prolonger tardivement pour certains individus.

Note : Les histogrammes concernant les athlètes féminines ainsi que l'ensemble des graphiques Quantile-Quantile (QQ-plots) sont consultables en Annexe.

Test statistique de normalité (Shapiro-Wilk)

Pour confirmer les observations visuelles, un test de **Shapiro-Wilk** a été réalisé sur chaque groupe (combinaison sexe/famille). Ce test évalue l'hypothèse nulle (H_0) de normalité des données. Si la p -value est inférieure au seuil de 5%, l'hypothèse de normalité est rejetée. Le tableau ci-dessous présente une sélection représentative des résultats obtenus.

Table 2: Sélection de résultats du test de normalité de Shapiro-Wilk par groupe

Famille	Sexe	Statistique W	p -value	Normalité
Sprint	Hommes	0.892	< 0.001	NON
Lancers	Hommes	0.914	< 0.001	NON
5000 - 10000	Hommes	0.883	< 0.001	NON
Sauts	Hommes	0.965	0.002	NON
Marathon	Femmes	0.927	0.033	NON
800 - 1500 - steeple	Hommes	0.969	0.023	NON

Famille	Sexe	Statistique W	p-value	Normalité
Épreuves combinées	Hommes	0.963	0.335	OUI
Marche	Femmes	0.942	0.083	OUI
Haies	Femmes	0.975	0.230	OUI

Note : L'intégralité des 18 tests (couvrant toutes les familles pour chaque sexe) est consultable en annexe. La majorité des groupes non mentionnés ici rejettent également l'hypothèse de normalité.

Conclusion sur le choix des tests

L'analyse du tableau Table 2 montre que l'hypothèse de normalité est rejetée pour la majorité des familles de disciplines. Ce résultat corrobore les observations visuelles : la distribution de l'âge au pic présente majoritairement une asymétrie positive, marquée par un seuil d'accès au haut niveau vers 20 ans et un maintien de la performance qui s'étire pour certains athlètes au-delà de 30 ans.

Bien que la normalité soit statistiquement acceptée pour quelques groupes isolés, une **méthodologie non paramétrique unique** est privilégiée pour l'ensemble de l'étude. Ce choix garantit la cohérence des comparaisons entre toutes les disciplines et assure la robustesse des résultats face aux distributions asymétriques observées.

Implication méthodologique : La distribution de l'âge au pic n'étant pas uniformément normale, l'utilisation de la moyenne et de l'écart-type comme seuls indicateurs serait trompeuse. Par conséquent :

1. La **médiane** et les **quartiles** sont privilégiés pour décrire les positions.
2. Des **tests non paramétriques**, fondés sur les rangs, sont exclusivement utilisés pour comparer les groupes dans la suite de l'analyse.

2.4 Analyse inférentielle : Influence du sexe et de la discipline

Méthodologie et raisonnement statistique

Le raisonnement statistique reposant sur la comparaison des rangs plutôt que des moyennes permet de s'affranchir des contraintes liées aux valeurs extrêmes et à l'asymétrie des données. Pour ce faire, les procédures suivantes ont été appliquées avec un seuil de significativité $\alpha = 0,05$:

- **Test de Wilcoxon-Mann-Whitney :** Ce test est mobilisé pour comparer l'âge au pic entre les sexes. Il teste si une distribution est statistiquement décalée par rapport à l'autre en se basant sur la somme des rangs.
- **Test de Kruskal-Wallis :** Utilisé pour comparer plus de deux groupes (les familles de disciplines). Il constitue l'alternative non paramétrique à l'ANOVA à un facteur et évalue si au moins une famille présente une médiane statistiquement différente des autres.
- **Test post-hoc de Dunn :** En cas de résultat significatif au test de Kruskal-Wallis, cette procédure est utilisée pour identifier quelles familles se distinguent spécifiquement les unes des autres. Une **correction de Bonferroni** est systématiquement appliquée aux p -values pour limiter le risque d'erreur de type I lié à la multiplicité des tests.

Résultats des tests globaux

Comparaison par sexe

Le test de Wilcoxon-Mann-Whitney confirme une différence statistiquement significative entre les deux distributions ($p = 0,0016$). Ce résultat permet de rejeter l'hypothèse d'une égalité des médianes et indique que, dans cet échantillon, l'âge au pic des athlètes féminines (médiane à 26 ans) est légèrement supérieur à celui des athlètes masculins (médiane à 25 ans).

Comparaison par familles de disciplines

Le test de Kruskal-Wallis met en évidence une forte hétérogénéité entre les spécialités athlétiques ($\chi^2 = 98,22, p < 0,001$). Les tests de comparaison par paires (Dunn) indiquent les tendances suivantes :

- Un contraste marqué est observé entre le **Marathon** et les épreuves de **Sprint** ($p_{adj} < 0,001$). Les résultats montrent un lien entre l’allongement de la distance de course et l’élévation de l’âge au pic.
- Les familles des **Lancers** et du **Sprint** présentent également des distributions significativement décalées ($p_{adj} < 0,001$), suggérant des dynamiques de maturité distinctes entre la puissance explosive courte et la force technique.
- À l’inverse, aucun lien statistique clair n’est mis en évidence entre les **Sauts** et les **Haies**, laissant supposer des contraintes physiologiques comparables.

Analyse détaillée par discipline

L’examen par épreuve individuelle permet d’identifier les disciplines où le lien entre sexe et maturité est le plus manifeste (Table 3).

Table 3: Principaux résultats du test de Wilcoxon par discipline

Discipline	Médiane Hommes	Médiane Femmes	p -value	Conclusion
800 Mètres	23.0	25.5	0.002	Significatif
10 000 Mètres	23.0	27.0	0.007	Significatif
Marathon	27.0	29.0	0.009	Significatif
Disque	28.0	25.5	0.012	Significatif

Sur l’ensemble des épreuves significatives, une tendance se dégage : le pic de performance féminin semble plus tardif, à l’exception du lancer du disque où le schéma inverse est observé.

2.5 Discussion

Les tests statistiques effectués suggèrent que l’âge au pic de performance pourrait être influencé par une interaction complexe entre le sexe et la nature de l’effort physique.

L’écart significatif identifié dans les disciplines d’endurance (10 000m, Marathon) permet de supposer que les carrières féminines dans ces spécialités pourraient suivre une trajectoire de maturité plus lente ou plus durable. Il est possible que des facteurs liés à la gestion des carrières ou à des capacités d’adaptation aérobie prolongées chez les femmes expliquent ce décalage d’un à quatre ans.

Cependant, l’absence de lien significatif dans les épreuves de sprint court (100m, 200m) ou de sauts suggère que pour les disciplines dépendant prioritairement de la puissance explosive, les contraintes biologiques pourraient imposer un cadre temporel plus rigide, identique pour les deux sexes.

Ces résultats doivent être interprétés avec prudence. Bien que les tests montrent des liens statistiques solides, ces derniers ne permettent pas d’affirmer une causalité biologique directe. Il est envisageable que des facteurs environnementaux ou l’organisation des circuits de compétition mondiaux participent à ces différences observées. Ces constats justifient toutefois l’intérêt d’une modélisation séparée par famille dans la suite de cette étude.

3 Etude 2 : Modèles

3.1 Méthodologie

De nombreux modèles ont déjà été élaborés afin de modéliser la relation entre l'âge et la performance en athlétisme. Nous allons nous concentrer sur le modèle de Moore (1975) ainsi que sur le modèle IMAP (2019). Ces deux modèles sont des modèles incluant une partie qui va croître avec l'âge jusqu'à atteindre un pic ainsi qu'une seconde partie de décroissance.

3.1.1 Modèle de Moore (1975)

Dans son modèle, Dan H. Moore explique la relation entre l'âge et la performance sur un large éventail d'âges, de 5 ans jusqu'à 75 ans. Il utilise l'équation suivante pour modéliser la performance en fonction de l'âge.

$$P(t) = a \cdot (1 - e^{-bt}) + c \cdot (1 - e^{dt}) \quad (1)$$

L'équation (??) est un modèle à double exponentielle, constitué de deux composantes :

- $P_1(t) = a(1 - e^{-bt})$: correspond à la phase d'amélioration des performances avec l'âge.
- $P_2(t) = c(1 - e^{dt})$: correspond à la phase de déclin des performances, liée au vieillissement.

Dans ce modèle, les paramètres a , b , c et d sont tous positifs et $P(t)$ correspond à la performance à l'âge t .

En s'appuyant sur l'expression analytique du pic $P(t_{pic}) = (a + c) - a \cdot R^{-\alpha} - c \cdot R^{1-\alpha}$ où $R = \frac{ab}{cd}$ et $\alpha = \frac{b}{b+d}$ ainsi que de sa position $t_{pic} = \frac{\ln(\frac{ab}{cd})}{b+d}$, on peut caractériser précisément le rôle de chaque paramètre. Les paramètres a et c gouvernent l'amplitude de la courbe mais agissent en sens opposés : a détermine le plateau vers lequel tend le terme montant et tire le pic vers le haut, tandis que c contrôle l'amplitude du terme descendant et l'abaisse. Leur rapport conditionne ainsi directement la valeur maximale atteinte par $P(t)$. Sous l'hypothèse $c \ll a$, a est le paramètre dominant : il fixe à lui seul l'ordre de grandeur du pic, et c n'en est qu'une correction.




Figure 4: Effet de a et c

Les paramètres b et d gouvernent quant à eux la dynamique temporelle de la courbe. b est la vitesse de montée, il est directement proportionnel à la pente initiale via $P'(0) = ab$ tandis que

d est la vitesse de descente, estimable depuis la pente de la phase tardive. Leur somme $b+d$ détermine l'étalement global de la courbe : une grande valeur de $b+d$ produit un pic étroit et précoce, une petite valeur un pic large et tardif. La position du pic $t_{pic} = \frac{\ln(\frac{ab}{cd})}{b+d}$ montre que b et d interagissent également avec a et c via le rapport $R = \frac{ab}{cd}$: le pic est d'autant plus tardif que la force du terme montant (ab) est grande devant celle du terme descendant (cd).




Figure 5: Effet de b et d

La position de t_{pic} a été obtenu en annulant la dérivée de $P(t)$. C'est-à-dire en annulant $P'(t) = ab \cdot e^{-bt} - cd \cdot e^{dt}$, l'équation $P'(t) = 0$ traduit l'équilibre instantané entre la vitesse de montée et la vitesse de descente. Ainsi, cette formule montre que ce n'est pas a seul ni b seul qui positionnent le pic, mais bien les produits ab et cd qui s'affrontent dans le rapport R . Sous l'hypothèse $c \ll a$, on a $cd \ll ab$, donc $R \gg 1$, $\ln(R) > 0$ et t^* est bien positif — le pic existe. Plus c est faible devant a , plus R est grand et plus le pic est tardif : la descente, peu vigoureuse, tarde à contrebalancer la montée. À l'inverse, un cas limite instructif est $a \cdot b = c \cdot d$, soit $R = 1$: $\ln(R) = 0$ et $t_{pic} = 0$, il n'y a plus de pic et la courbe est décroissante dès l'origine. C'est pourquoi la contrainte $ab > cd$ constitue non seulement une condition de positivité des paramètres, mais bien la condition d'existence du pic.

3.1.2 Modèle IMAP (2019)

Le modèle IMAP (*Integrative Model of Age-Performance*), développé par Berthelot et al. en 2019, propose une approche biologiquement fondée de la relation âge-performance, en modélisant la dynamique des populations cellulaires au cours de la vie. Contrairement au modèle de Moore, dont les paramètres sont purement empiriques, l'IMAP s'appuie sur deux mécanismes cellulaires distincts : la sénescence répliquative $\alpha(t)$, qui décrit la croissance puis la saturation de la population cellulaire, et la perte de fonctionnalité cellulaire $\beta(t)$, qui traduit le déclin progressif lié au vieillissement. La performance $P(t)$ à l'âge t est alors donnée par :

$$P(t) = \beta_0 N_\infty \cdot e^{\frac{\alpha_0}{\alpha_r}(1-e^{-\alpha_r t})} \cdot (1 - e^{\beta_r(t-t_d)}) \quad (2)$$

où N_∞ est la taille asymptotique de la population cellulaire, $\alpha_0 > 0$ et $\alpha_r > 0$ contrôlent respectivement le taux initial et la vitesse de saturation de la croissance cellulaire, $\beta_0 > 0$ et $\beta_r > 0$ contrôlent le taux et la vitesse du déclin fonctionnel, et $t_d > 0$ est un paramètre explicite correspondant à l'âge de décès. Ce dernier paramètre constitue une différence importante avec




Figure 6: Effet des paramètres sur t_{pic}

le modèle de Moore : il assure une convergence contrôlée de la courbe et réduit la variabilité des estimations aux âges avancés.

3.1.3 Méthode générale

* Précautions pour gérer le déséquilibre des âges

On note dans nos données un fort déséquilibre dans la distribution des âges (très peu d'âges dits « élevés » et très peu d'âges dits « faibles »). La figure suivante illustre cela, entre 20 et 30 ans, il y a beaucoup plus de points qu'avant 20 ans ou après 30 ans. Il va falloir gérer ce problème car comme chaque point a le même poids, les âges où nous avons beaucoup de points risquent d'influencer fortement notre modèle.

Pour cela, nous allons garder pour chaque âge la meilleure performance réalisée et estimer nos modèles à partir de ces données.

* Descente de gradients

Pourquoi cette méthode ?

La méthode de la descente de gradient est nécessaire car dans le cadre du modèle de Moore comme pour le modèle IMAP, les formules présentent une non-linéarité par rapport à certains paramètres. La non-linéarité est selon les paramètres b et d , situés en exposants pour le modèle de Moore et selon les paramètres α_r , β_r et α_0 . Contrairement à une régression linéaire classique (MCO), il n'existe pas de formule explicite permettant de calculer directement les coefficients optimaux par une simple inversion matricielle. La structure même de l'équation, composée de deux membres bi-exponentiels, crée une interdépendance forte : il devient difficile d'isoler l'influence de chaque partie sur l'allure globale de la courbe, car les deux termes "se mélangent" pour produire le résultat final. Là où une régression linéaire tenterait de trouver une solution globale et instantanée, la descente de gradient adopte une approche plus fine et progressive. Elle ajuste les paramètres et de concert, avançant pas à pas dans toutes les directions pour minimiser l'erreur, permettant ainsi de calibrer précisément le modèle là où les méthodes directes échouent.

Fonctionnement




Figure 7: Top 32




Figure 8: Meilleure par age

La descente de gradient est un algorithme d'optimisation itératif du premier ordre. Son objectif est de déterminer le jeu de paramètres $\theta = \theta_1, \dots, \theta_n$ qui minimise une fonction de coût (ou fonction de perte), notée $J(\theta)$. Dans ce cadre, nous utilisons l'Erreur Quadratique Moyenne (MSE), qui mesure l'écart entre les prédictions du modèle et les observations réelles. Le gradient, noté $\nabla J(\theta)$, est le vecteur regroupant les dérivées partielles de la fonction de coût par rapport à chaque paramètre :

$$\nabla J(\theta) = \begin{pmatrix} \frac{\partial J}{\partial \theta_1} \\ \vdots \\ \frac{\partial J}{\partial \theta_n} \end{pmatrix}$$

Mathématiquement, ce vecteur pointe toujours vers la direction de la plus forte augmentation de la fonction. Par conséquent, pour minimiser l'erreur, l'algorithme doit se déplacer dans la direction opposée au gradient. L'algorithme démarre d'une initialisation arbitraire et met à jour les paramètres de manière itérative selon la règle suivante : $\theta_{next} = \theta_{current} - \eta \cdot \nabla J(\theta)$. Dans cette formule, η représente le taux d'apprentissage (learning rate). C'est un hyperparamètre crucial qui détermine la taille du pas effectué à chaque étape : - S'il est trop grand, l'algorithme risque d'osciller et de ne jamais converger. - S'il est trop petit, la progression sera extrêmement lente. L'opération est répétée jusqu'à la convergence, c'est-à-dire lorsque le gradient devient proche de zéro (indiquant que nous avons atteint un minimum) ou lorsque le nombre maximal d'itérations est atteint.

Optimum local

La descente de gradient est une méthode permettant d'obtenir un optimum local qu'il faut distinguer de l'optimum global. En effet, l'optimum local dépend du point d'où nous décidons de partir et n'est pas forcément le meilleur optimum. Dans cette méthode, le point de départ choisi joue donc un rôle essentiel et a une influence considérable sur les paramètres estimés. Pour contrer ce problème, nous allons estimer plusieurs modèles (1000) pour chaque couple (Sex, discipline) en générant de façon aléatoire les points de départ pour chacune des estimations.




Figure 9: Optimum local et descente de gradient

* Introduction de l'aléatoire

Le point de départ choisi jouant un rôle essentiel dans la détermination des paramètres estimés, il est essentiel d'ajouter une part d'aléatoire dans le choix de ces paramètres. Ainsi nous estimerons

plusieurs fois chaque modèle avec des points de départ généré aléatoirement à chaque fois. Nous allons ainsi estimer 1 000 modèles pour chaque couple afin de maximiser nos chances d'en avoir qui convergent et pouvoir ensuite choisir le plus performant.

L'aléatoire dans le modèle de Moore

Initialisation des paramètres du modèle

Afin d'estimer les paramètres du modèle de Moore, nous devons fournir à l'algorithme de descente de gradient des valeurs initiales pour a, b, c et d . Celles-ci sont générées aléatoirement à partir des propriétés observables de la série de données, selon le schéma suivant :

- a est tiré uniformément entre 0,9 et 1,2 fois la valeur de performance maximale observée, reflétant le fait que le plateau asymptotique du terme montant est légèrement supérieur au pic ;
- b est tiré uniformément autour du rapport $\frac{\text{pente initiale}}{a}$, conformément à l'approximation $f'(0) \approx ab$ valable lorsque $c \ll a$;
- c est tiré uniformément dans un voisinage étroit de $a/100$, traduisant l'hypothèse que le terme descendant est une petite perturbation devant le terme montant ;
- d est tiré uniformément autour de l'estimateur $\frac{\ln[(f(t_3)-a)/(f(t_4)-a)]}{t_3-t_4}$, obtenu par régression sur deux points situés dans la phase descendante de la courbe.

Par ailleurs, les quatre paramètres étant par définition strictement positifs, des contraintes de positivité sont imposées lors de la génération, sans restriction sur les valeurs maximales.

* Adaptation du modèle IMAP à nos données

Le modèle IMAP tel que proposé par Berthelot et al. (2019) a été conçu pour des données couvrant l'ensemble du cycle de vie, de 5 à 75 ans environ. Dans ce cadre, les six paramètres — $\alpha_0, \alpha_r, \beta_0, N_\infty, \beta_r$ et t_d — sont tous identifiables car la courbe présente à la fois une phase de croissance complète, un pic prononcé et une phase de déclin étendue.

Notre jeu de données couvre en revanche une fenêtre beaucoup plus restreinte, de 16 à 40 ans, correspondant aux carrières des athlètes d'élite. Cette troncature crée un problème d'**identifiabilité** : les paramètres β_0 et N_∞ n'apparaissant que sous forme de produit dans la formule, ils ne peuvent pas être estimés séparément. Ils ont donc été fusionnés en un unique paramètre d'amplitude $A = \beta_0 N_\infty$, ramenant le nombre de paramètres libres à quatre : A, α_0, α_r et β_r . La formule estimée est ainsi :

$$P(t) = A \cdot e^{\frac{\alpha_0}{\alpha_r}(1-e^{-\alpha_r t})} \cdot (1 - e^{\beta_r(t-t_d)})$$

Choix du paramètre t_d

Le paramètre t_d , qui représente dans le modèle original l'espérance de vie de l'athlète, ne peut pas être estimé de façon fiable sur des données tronquées à 40 ans : la phase de déclin terminal est trop peu visible dans la fenêtre d'observation pour contraindre ce paramètre. Des tests ont confirmé que laisser t_d libre conduit systématiquement à une matrice de gradient singulière et à l'absence de convergence.

Nous avons donc fixé t_d à une valeur supérieure à l'âge maximal observé dans chaque groupe (discipline $\times$ sexe), en testant huit valeurs : $t_d = \max(\text{Age}) + \delta$ avec $\delta \in \{10, 15, 20, 25, 30, 35, 40, 45\}$. Pour chaque valeur de δ , 500 estimations sont lancées avec des points de départ aléatoires, et la valeur retenue est celle qui minimise le RMSE sur l'ensemble des huit candidats.

Cette approche garantit que le terme de déclin est suffisamment visible dans la fenêtre d'observation pour que le gradient soit non singulier, tout en restant cohérente avec l'interprétation de t_d comme horizon temporel au-delà duquel la performance décline rapidement. Il convient de noter que t_d ne représente plus ici l'âge de décès biologique au sens strict, mais un paramètre de calibration lié à la fenêtre des données.

L'aléatoire dans le modèle IMAP

Comme pour le modèle de Moore, le problème des optima locaux est géré par une procédure de dépôts multiples aléatoires. Les points de départ des quatre paramètres libres sont générés aléatoirement à chaque itération, selon une logique proportionnelle à t_d inspirée des travaux de Berthelot et al. (2019) :

- A est tiré négativement dans l'intervalle $[-0,003 \cdot t_d ; -0,002 \cdot t_d]$, reflétant le fait que le terme de déclin impose $A < 0$ pour que la courbe reste positive sur la fenêtre d'observation ;
- α_0 est tiré dans $[0,00075 \cdot t_d ; 0,00325 \cdot t_d]$;
- α_r est tiré dans $[0,00225 \cdot t_d ; 0,00325 \cdot t_d]$;
- β_r est tiré négativement dans $[-0,0015 \cdot t_d ; -0,0005 \cdot t_d]$.

Pour chaque valeur de t_d testée, 500 modèles sont estimés et le meilleur — au sens du RMSE — est retenu. Au total, 4 000 estimations sont donc réalisées par couple (sexe $\times$ discipline).

* Choix du modèle le plus performant : Critère d'optimisation

Une fois les modèles estimés, il va nous falloir déterminer les paramètres optimaux pour chaque modèle afin de résumer au mieux les données et obtenir une courbe la plus représentative possible. Il nous faut donc un critère d'optimisation. Le critère d'optimisation que nous allons utiliser est assez classique : il s'agit de l'erreur quadratique (ou méthode des moindres carrés). Ce critère consiste à minimiser la somme des erreurs quadratiques, notée :

$$S(\theta) = \sum_{i=1}^N (f_i - \hat{f}(age_i, \theta))^2$$

On cherche donc :

$$\arg \min_{\theta} \sum_{i=1}^N (f_i - \hat{f}(age_i, \theta))^2$$

.

Pour chaque couple (sexe, discipline), nous allons choisir parmi les différents modèles estimés (et ayant donc convergés) celui qui MSE. On trouve ainsi les paramètres correspondant au modèle le plus performant.

* Comparaison des modèles : AIC et BIC

Afin de comparer les différents modèles de régression linéaire considérés dans cette étude, les critères d'information AIC (Akaike Information Criterion) et BIC (Bayesian Information Criterion) sont utilisés. Ces deux critères reposent sur une logique commune : pénaliser la complexité du modèle afin d'éviter le surapprentissage, tout en cherchant à minimiser l'erreur de prévision sur de nouvelles observations.

AIC : Akaike Information Criterion

L'AIC est défini par

$$AIC = n \cdot \ln\left(\frac{SRC}{n}\right) + 2(p + 1)$$

où n désigne le nombre d'observations, p le nombre de variables explicatives retenues dans le modèle, et SCR la somme des carrés des résidus. Cette formule, valable sous hypothèse de normalité des erreurs, quantifie l'erreur de prévision via la divergence de Kullback-Leibler.

BIC : Bayesian Information Criterion

Le BIC est quant à lui défini par

$$BIC = n \cdot \ln\left(\frac{SRC}{n}\right) + (p + 1) \cdot \ln(n),$$

et se distingue de l'AIC uniquement par le remplacement du facteur 2 par

$$\ln(n)$$

dans le terme de pénalité. Bien que proches dans leur formulation, ces deux critères conduisent fréquemment au choix de modèles différents.

Pour chacun de ces critères, le modèle retenu est celui présentant la valeur la plus faible.

3.2 Résultats

Résultats du modèle IMAP

Le modèle IMAP a convergé pour l'ensemble des 42 couples (sexe $\times$ discipline). Le Tableau 4 présente les âges au pic estimés par groupe de disciplines.

Table 4: Âge au pic estimé par le modèle IMAP selon le groupe de disciplines et le sexe

Groupe	Sexe	t_{pic} moyen	Min	Max
Sprint	Hommes	27,1	25,3	29,2
Sprint	Femmes	27,3	26,8	28,2
Haies	Hommes	27,0	26,9	27,0
Haies	Femmes	27,2	26,4	28,0
Demi-fond	Hommes	26,6	25,2	27,7
Demi-fond	Femmes	26,1	24,9	27,1
Fond	Hommes	25,2	24,9	25,4
Fond	Femmes	27,0	25,8	28,3
Marathon	Hommes	29,5	29,5	29,5
Marathon	Femmes	29,8	29,8	29,8
Marche	Hommes	28,2	28,2	28,2
Marche	Femmes	27,3	27,3	27,3
Lancers	Hommes	28,6	26,8	30,0
Lancers	Femmes	27,6	27,2	28,3
Sauts	Hommes	27,2	26,3	28,4
Sauts	Femmes	27,9	27,0	28,7
Combinées	Hommes	26,6	26,6	26,6
Combinées	Femmes	25,3	25,3	25,3

Plusieurs tendances se dégagent. Premièrement, le modèle IMAP identifie des âges au pic se situant entre 25 et 30 ans pour la majorité des estimations.

Le marathon constitue l'exception la plus nette, avec un pic estimé à 29,5 ans chez les hommes et 29,8 ans chez les femmes — valeurs cohérentes avec la littérature sur l'endurance longue, qui souligne le rôle de l'expérience et de la maturité physiologique dans cette discipline.

Les différences entre sexes sont faibles et non systématiques : les femmes présentent un pic légèrement plus tardif dans les sauts (+0,7 an en moyenne) et au marathon (+0,3 an), mais légèrement plus précoce dans les épreuves de fond et les épreuves combinées. Ces écarts restent dans une marge de 1 à 2 ans, ce qui suggère que le sexe n'est pas un facteur déterminant de l'âge au pic de performance en athlétisme d'élite. (faire les tests)

Concernant la qualité d'ajustement, le RMSE varie fortement selon la nature de la performance mesurée. Les disciplines techniques exprimées en mètres (lancers notamment, RMSE moyen de 1,57 m chez les hommes) présentent des erreurs absolues plus élevées que les disciplines où la performance est exprimée en km/h (marche athlétique, RMSE < 0,01). Cette hétérogénéité peut s'expliquer par les différences d'échelle entre les variables de performance et ne reflète pas une moindre qualité d'ajustement relatif.

exemple du marathon

La Figure 5 présente les ajustements obtenus pour les marathonniens et marathonniennes du Top 39. Chez les hommes, le modèle estime un pic de performance à **29,5 ans**, avec un t_d retenu de 65 ans. La courbe capture bien la phase de progression rapide entre 18 et 28 ans, le plateau autour de 29–31 ans, puis le déclin progressif jusqu'à 40 ans. L'ajustement est visuellement satisfaisant, les résidus ne présentant pas de structure systématique.

Chez les femmes, le pic estimé est légèrement plus tardif à **29,8 ans**, avec un t_d retenu de 85 ans. La dispersion des points est plus importante que chez les hommes — notamment la présence d'une performance exceptionnelle à 35 ans (18,49 km/h) qui s'écarte nettement de la tendance centrale — ce qui se traduit par un RMSE légèrement plus élevé (0,20 km/h) et des critères AIC et BIC moins favorables. La courbe capture néanmoins bien la dynamique générale, avec une phase de croissance plus progressive que chez les hommes et un déclin légèrement plus marqué après 32 ans.

La similitude des âges au pic entre hommes (29,5 ans) et femmes (29,8 ans) au marathon est cohérente avec la littérature sur l'endurance longue, qui souligne que cette discipline requiert une maturité physiologique et une expérience de course accumulée sur plusieurs années, indépendamment du sexe [?].




Figure 10: Ajustement du modèle IMAP sur le marathon (hommes et femmes). Points : meilleure performance annuelle par âge. Ligne rouge : courbe ajustée.

3.3 Discussion

4 Discussion générale

Conclusion

Remerciements

Références

Voici la liste de toutes les références bibliographiques utiles à la rédaction de ce rapport :

Allen, Sian V., et Will G. Hopkins. 2015. « Age of Peak Competitive Performance of Elite Athletes: A Systematic Review ». *Sports Medicine*.

Carter, P. A. et al. s. d. « The age-performance relationship in the general population and strategies to delay age related decline in performance ». *Archives of Public Health*. <https://doi.org/10.1186/s13690-019-0375-8>.

InfographicSite. 2021. « Olympians Age Distribution by Gender - Tokyo 2020 ». 2021. <https://infographicsite.com/infographic/olympians-age-distribution-by-gender/>.

Annexes

4.1 Compléments de l'analyse de distribution

Cette section regroupe les graphiques de diagnostic complémentaires permettant de valider les choix statistiques effectués dans le corps du rapport.

4.1.1 Distributions des athlètes féminines

La figure ci-dessous complète l'analyse descriptive en présentant les histogrammes de l'âge au pic pour les femmes.




Figure 11: Distributions de l'âge au pic de performance (Athlètes féminines)

4.1.2 Analyse de la normalité (QQ-Plots)

Les graphiques Quantile-Quantile (QQ-plots) permettent de visualiser l'écart entre nos données observées et une distribution normale théorique (représentée par la ligne droite). Un écart des points par rapport à cette ligne confirme la non-normalité.

===== ## Annexe : Modèles de Moore

Quantile-quantile de l'âge au pic des athlètes masculins




Figure 12: QQ-plot de l'âge au pic (Hommes)

Quantile-quantile de l'âge au pic des athlètes féminines




Figure 13: QQ-plot de l'âge au pic (Femmes)




Figure 14: Lancers




Figure 15: Sauts




Figure 16: Sprint




Figure 17: Haies




Figure 18: Demi-fond




Figure 19: 5000m - 10000m




Figure 20: Marathon




Figure 21: Marche




Figure 22: Epreuves combinées