

RAPPORT DE PROJET STATISTIQUE

Élèves 2A

Titre choisi pour mon rapport en Quarto

Étudiants :

Arthur DELETANG
Maëlys D'HALLUIN
Clémence PINSARD

Tuteur :

Imad Hamri

Résumé

La détection précoce des talents sportifs et la compréhension de la trajectoire des athlètes d'élite constituent des enjeux majeurs pour les fédérations sportives internationales. Cette étude s'intéresse à la relation entre l'âge et la performance en athlétisme, en cherchant à identifier l'âge au pic de performance selon les disciplines et le sexe. Mieux comprendre cette dynamique permet non seulement d'optimiser la planification des carrières sportives, mais aussi d'améliorer les stratégies de détection et d'accompagnement des jeunes athlètes. L'analyse s'appuie sur les données de World Athletics couvrant la période 1985–2024, recensant les 100 meilleures performances annuelles mondiales par discipline et par sexe. Deux modèles non linéaires sont mobilisés : le modèle de Moore (1975) et le modèle IMAP (Berthelot et al., 2019), appliqués à trois familles de disciplines — sprint, lancers et endurance. Cette étude permet de comparer les dynamiques de progression et de déclin entre disciplines et entre sexes, et ainsi contribuer à une meilleure connaissance du vieillissement athlétique.

Abstract

Early talent detection and understanding the career trajectories of elite athletes are key challenges for international sports federations. This study examines the relationship between age and performance in athletics, aiming to identify peak performance age across disciplines and sexes. A deeper understanding of this dynamic can help optimize career planning and improve strategies for identifying and supporting young athletes. The analysis draws on World Athletics data spanning 1985–2024, covering the top 100 annual performances worldwide per discipline and sex. Two nonlinear models are applied : the Moore model (1975) and the IMAP model (Berthelot et al., 2019), across three discipline families — sprints, throws, and endurance. This study allows us to compare the dynamics of progression and decline between disciplines and between sexes, and thus contribute to a better understanding of athletic aging.

Mots-clés

Table des matières

Résumé	1
Abstract	1
Mots-clés	1
Introduction	3
Contexte et enjeux	3
Objectif de l'étude	3
Questions de recherches et trajectoires attendues	3
1 Présentation des données	5
1.1 Préparation et nettoyage des données	5
1.2 Variables d'intérêt	5
2 Etude 1 : statistiques descriptives	7
2.1 Méthodologie	7
2.2 Résultats	7
2.3 Discussion	7
3 Etude 2 : Modèles	8
3.1 Méthodologie	8
3.1.1 Modèle de Moore (1975)	8
3.1.2 Modèle IMAP (2019)	8
3.1.3 Méthode générale	8
3.2 Initialisation des paramètres du modèle	10
3.3 Résultats	11
3.4 Discussion	11
4 Discussion générale	12
Conclusion	13
Remerciements	14
Références	15
Annexes	16

Introduction

Contexte et enjeux

La détection précoce des talents sportifs constitue un enjeu majeur pour les fédérations internationales d'athlétisme. Si la question de l'identification des jeunes athlètes prometteurs semble intuitive, elle se révèle en réalité bien plus complexe : les performances exceptionnelles observées à l'adolescence ne garantissent pas nécessairement la réussite au plus haut niveau à l'âge adulte. Ce constat soulève une problématique centrale : comment identifier, parmi les jeunes athlètes performants, ceux qui parviendront à maintenir, voire améliorer leur niveau dans les années suivantes ?

Cette question s'inscrit dans un contexte scientifique où la relation entre l'âge et la performance sportive a fait l'objet de nombreuses recherches. Depuis les travaux pionniers de Moore en 1975, qui proposa le premier modèle mathématique de cette relation, la communauté scientifique n'a cessé d'approfondir la compréhension de cette dynamique. Plus récemment, Berthelot et ses collaborateurs ont développé en 2019 le modèle IMAP (Integrative Model of Age-Performance), fondé sur des mécanismes biologiques cellulaires, offrant ainsi une nouvelle perspective pour modéliser l'évolution des capacités physiques tout au long de la vie.

Notre étude s'appuie sur une base de données internationale fournie par World Athletics, couvrant la période 2000-2024 et recensant les 100 meilleures performances annuelles, pour chaque sexe, dans chaque discipline athlétique. Ce corpus, portant sur plusieurs dizaines de milliers de performances au plus haut niveau mondial, permet d'analyser finement la trajectoire des athlètes d'élite à travers différentes disciplines.

Objectif de l'étude

L'objectif principal de ce projet est d'analyser la relation entre l'âge et la performance en athlétisme. Plus spécifiquement, nous cherchons à comprendre comment évoluent les performances athlétiques au fil du temps et à déterminer l'âge auquel les athlètes atteignent leur pic de performance.

Contrairement aux approches basées uniquement sur l'âge moyen des athlètes, qui peuvent être biaisées par les différences d'âge de début et de fin de carrière selon les pays ou les disciplines, notre étude se concentre sur l'identification de l'âge au pic de performance. Cette approche permet de mieux comprendre la dynamique temporelle de la performance sportive, caractérisée par une phase de croissance progressive des capacités, suivie d'un plateau puis d'un déclin lié au vieillissement.

Questions de recherches et trajectoires attendues

L'analyse de nos données vise à répondre à plusieurs interrogations fondamentales sur la dynamique de la performance athlétique. La littérature scientifique nous guide dans la formulation de nos attentes quant aux résultats escomptés.

Tout d'abord, nous cherchons à caractériser la variabilité de l'âge au pic de performance selon les disciplines. Les travaux d'Allen et Hopkins² ont établi une relation claire entre la durée de l'épreuve et l'âge optimal de performance : dans les épreuves de puissance explosive et de sprint, l'âge au pic décroît avec la durée de l'effort, allant d'environ 27 ans pour les lancers à 20 ans pour les sprints courts en natation. À l'inverse, pour les épreuves d'endurance, l'âge au pic augmente avec la durée, s'échelonnant d'environ 20 ans pour les épreuves courtes à près de 39 ans pour l'ultra-endurance cycliste. Cette tendance s'explique par les différences dans les systèmes énergétiques sollicités et le temps nécessaire au développement complet des capacités aérobies. Nous nous attendons donc à observer dans nos données un âge au pic plus précoce pour les épreuves de sprint et de saut, et plus tardif pour les disciplines d'endurance comme le demi-fond et le fond.

La question des différences entre sexes mérite également une attention particulière. Bien que plusieurs études, notamment celle d'Allen et Hopkins², rapportent peu de différences entre hommes et femmes dans l'âge au pic de performance pour les épreuves explosives et d'endurance, d'autres travaux suggèrent une distinction : l'analyse des Jeux Olympiques 2020 ³ révèle que l'âge moyen des athlètes masculins est d'un an supérieur à celui des femmes. De plus, des études sur le vieillissement athlétique indiquent que le déclin de performance avec l'âge pourrait être plus marqué chez les femmes que chez les hommes dans certaines disciplines, particulièrement en sprint, tandis que cette différence s'atténue dans les épreuves d'endurance longue. Nos analyses chercheront à confirmer ou infirmer ces tendances sur notre échantillon d'athlètes.

Enfin, la dynamique temporelle de la performance nous intéresse particulièrement. La relation âge-performance suit typiquement une forme asymétrique en U inversé : une phase de croissance progressive durant l'enfance et l'adolescence, un plateau lors du pic de performance à l'âge adulte, puis un déclin dont la vitesse s'accélère après 70 ans. Carter ⁴ décrit cette asymétrie comme une caractéristique fondamentale du vieillissement humain. La phase de croissance et la phase de déclin ne sont pas symétriques, et cette asymétrie pourrait varier selon les disciplines. Les épreuves de puissance, qui dépendent fortement des fibres musculaires rapides, connaissent un déclin plus précoce et prononcé que les épreuves d'endurance, où la perte de capacité aérobie est plus progressive. Nous explorerons donc la vitesse de progression en début de carrière et la vitesse de déclin après le pic, en comparant ces dynamiques entre disciplines et entre sexes. \

1 Présentation des données

Notre étude s'appuie sur une base de données issue de World Athletics, la fédération sportive internationale chargée de régir les fédérations nationales d'athlétisme et d'organiser les compétitions internationales mondiales¹. Cette base recense, pour chaque discipline et chaque année entre 1985 et 2024, les 100 meilleures performances mondiales réalisées lors de compétitions officielles. \

Les données comportent plusieurs variables clés : l'identifiant de l'athlète, son âge au moment de la performance, son sexe, sa nationalité, la discipline pratiquée, la performance brute (temps, distance ou hauteur selon la discipline) et le ResultScore. Ce dernier, développé par World Athletics, constitue une métrique normalisée permettant de comparer les performances entre disciplines différentes en s'appuyant sur des paramètres définis par des experts du domaine. \

La base couvre l'ensemble des disciplines olympiques en athlétisme : courses (sprint, demi-fond, fond, haies, relais), sauts (hauteur, longueur, triple saut, perche), lancers (poids, disque, javelot, marteau) et épreuves combinées (décathlon, heptathlon). Cette diversité permet d'analyser finement les spécificités de chaque famille de disciplines. \

Il convient toutefois de noter certaines limites structurelles : un déséquilibre dans la répartition des athlètes par âge, avec une sous-représentation des athlètes de plus de 35 ans, ainsi qu'une possible hétérogénéité dans la qualité de l'enregistrement des données selon les périodes et les pays. Ces biais potentiels seront pris en compte dans notre analyse et discutés dans l'interprétation des résultats.

1.1 Préparation et nettoyage des données

Le passage des données brutes à un échantillon exploitable a nécessité un protocole de nettoyage, articulé autour de quatre étapes clés : - **Calcul de l'âge et nettoyage initial** : Les entrées ne disposant pas de performance numérique exploitable ou d'une date de naissance valide ont été écartées. L'âge de chaque athlète a été calculé par la différence entre l'année de la performance (*season*) et son année de naissance.

- **Identification des carrières terminées** : Afin d'éviter le biais de troncature (inclure un athlète n'ayant pas encore atteint son pic), nous avons restreint l'étude aux athlètes retraités. Un seuil de "retraite" a été fixé à l'année 2022 : tout athlète ayant réalisé une performance après cette date a été considéré comme actif et exclu de l'analyse.

- **Sélection de la meilleure performance annuelle** : Pour chaque athlète, à chaque âge et dans chaque discipline, nous n'avons conservé que la meilleure performance annuelle. Cette étape permet d'éliminer les variations de forme intra-saisonnières. Les disciplines ont ensuite été regroupées en trois familles majeures : **Sprint**, **Lancers** et **Endurance**.

- **Filtrage par expérience et équilibrage (Top 39)** : Pour garantir que l'âge au pic observé soit représentatif d'une trajectoire complète, seuls les athlètes ayant au moins **5 années de performances** enregistrées dans une même discipline ont été retenus. Enfin, pour corriger les disparités d'effectifs entre les sexes, nous avons procédé à un échantillonnage équilibré en sélectionnant le **Top 39** des meilleurs athlètes par discipline et par sexe, seuil défini par l'effectif le plus restreint du jeu de données (lancer du disque féminin).

1.2 Variables d'intérêt

L'analyse repose sur un ensemble de variables structurées pour répondre à la problématique de l'évolution de la performance :

Age_Pic_Obs : L'âge auquel l'athlète a réalisé son record personnel absolu au cours de sa carrière. Il s'agit de notre variable dépendante centrale.

Sex : Pour comparer les performances entre les femmes et les hommes

Famille : Regroupement des disciplines par filières énergétiques (Sprint, Lancers, Endurance).

1. https://fr.wikipedia.org/wiki/World_Athletics

Discipline : Pour observer les ressemblances et différences entre les 24 disciplines en athlétisme.
meilleure_perf_km_par_h : Conversion de la performance en kilomètre par heure afin d'avoir des valeurs positives à maximiser dans nos modèles

2 Etude 1 : statistiques descriptives

Dans l'optique de mieux comprendre la structure de notre échantillon d'élite et d'en avoir une vue d'ensemble, il convient d'examiner d'abord les caractéristiques de l'âge au pic observé. Cette analyse préliminaire permet d'identifier des tendances majeures et de justifier le choix des modélisations non linéaires (Moore et IMAP) qui suivront.

2.1 Méthodologie

2.2 Résultats

2.3 Discussion

3 Etude 2 : Modèles

3.1 Méthodologie

De nombreux modèles ont déjà été élaborés afin de modéliser la relation entre l'âge et la performance en athlétisme. Nous allons nous concentrer sur le modèle de Moore (1975) ainsi que sur le modèle IMAP (2019). Ces deux modèles sont des modèles incluant une partie qui va croître avec l'âge jusqu'à atteindre un pic ainsi qu'une seconde partie de décroissance.

3.1.1 Modèle de Moore (1975)

Dans son modèle, Dan H. Moore explique la relation entre l'âge et la performance sur un large éventail d'âges, de 5 ans jusqu'à 75 ans. Il utilise l'équation suivante pour modéliser la performance en fonction de l'âge.

$$P(t) = a \cdot (1 - e^{-bt}) + c \cdot (1 - e^{dt}) \quad (1)$$

L'équation (??) est un modèle à double exponentielle, constitué de deux composantes :

- $P_1(t) = a(1 - e^{-bt})$: correspond à la phase d'amélioration des performances avec l'âge.
- $P_2(t) = c(1 - e^{dt})$: correspond à la phase de déclin des performances, liée au vieillissement.

Dans ce modèle, les paramètres a , b , c et d sont tous positifs et $P(t)$ correspond à la performance à l'âge t .

3.1.2 Modèle IMAP (2019)

Le modèle IMAP (*Integrative Model of Age-Performance*), développé par Berthelot et al. en 2019, propose une approche biologiquement fondée de la relation âge-performance, en modélisant la dynamique des populations cellulaires au cours de la vie. Contrairement au modèle de Moore, dont les paramètres sont purement empiriques, l'IMAP s'appuie sur deux mécanismes cellulaires distincts : la sénescence répliquative $\alpha(t)$, qui décrit la croissance puis la saturation de la population cellulaire, et la perte de fonctionnalité cellulaire $\beta(t)$, qui traduit le déclin progressif lié au vieillissement. La performance $P(t)$ à l'âge t est alors donnée par :

$$P(t) = \beta_0 N_\infty \cdot e^{\frac{\alpha_0}{\alpha_r}(1 - e^{-\alpha_r t})} \cdot (1 - e^{\beta_r(t - t_d)}) \quad (2)$$

où N_∞ est la taille asymptotique de la population cellulaire, $\alpha_0 > 0$ et $\alpha_r > 0$ contrôlent respectivement le taux initial et la vitesse de saturation de la croissance cellulaire, $\beta_0 > 0$ et $\beta_r > 0$ contrôlent le taux et la vitesse du déclin fonctionnel, et $t_d > 0$ est un paramètre explicite correspondant à l'âge de décès. Ce dernier paramètre constitue une différence importante avec le modèle de Moore : il assure une convergence contrôlée de la courbe et réduit la variabilité des estimations aux âges avancés.

3.1.3 Méthode générale

Précautions pour gérer le déséquilibre des âges

On note dans nos données un fort déséquilibre dans la distribution des âges (très peu d'âges dits « élevés » et très peu d'âges dits « faibles »). Il va falloir gérer ce problème car comme chaque point a le même poids, les âges où nous avons beaucoup de points risquent d'influencer fortement notre modèle. Pour cela, nous allons garder pour chaque âge la meilleure performance réalisée et estimer nos modèles à partir de ces données.

Descente de gradients

Pourquoi cette méthode ?

La méthode de la descente de gradient est nécessaire car dans le cadre du modèle de Moore comme pour le modèle IMAP, les formules présentent une non-linéarité par rapport à certains paramètres. La non-linéarité est selon les paramètres b et d , situés en exposants pour le modèle de Moore et selon les paramètres α_r , β_r et α_0 . Contrairement à une régression linéaire classique (MCO), il n'existe pas de formule explicite permettant de calculer directement les coefficients optimaux par une simple inversion matricielle. La structure même de l'équation, composée de deux membres bi-exponentiels, crée une interdépendance forte : il devient difficile d'isoler l'influence de chaque partie sur l'allure globale de la courbe, car les deux termes "se mélangent" pour produire le résultat final. Là où une régression linéaire tenterait de trouver une solution globale et instantanée, la descente de gradient adopte une approche plus fine et progressive. Elle ajuste les paramètres et de concert, avançant pas à pas dans toutes les directions pour minimiser l'erreur, permettant ainsi de calibrer précisément le modèle là où les méthodes directes échouent.

Fonctionnement

La descente de gradient est un algorithme d'optimisation itératif du premier ordre. Son objectif est de déterminer le jeu de paramètres $\theta = \theta_1, \dots, \theta_n$ qui minimise une fonction de coût (ou fonction de perte), notée $J(\theta)$. Dans ce cadre, nous utilisons l'Erreur Quadratique Moyenne (MSE), qui mesure l'écart entre les prédictions du modèle et les observations réelles. Le gradient, noté $\nabla J(\theta)$, est le vecteur regroupant les dérivées partielles de la fonction de coût par rapport à chaque paramètre :

$$\nabla J(\theta) = \begin{pmatrix} \frac{\partial J}{\partial \theta_1} \\ \vdots \\ \frac{\partial J}{\partial \theta_n} \end{pmatrix}$$

Mathématiquement, ce vecteur pointe toujours vers la direction de la plus forte augmentation de la fonction. Par conséquent, pour minimiser l'erreur, l'algorithme doit se déplacer dans la direction opposée au gradient. L'algorithme démarre d'une initialisation arbitraire et met à jour les paramètres de manière itérative selon la règle suivante : $\theta_{next} = \theta_{current} - \eta \cdot \nabla J(\theta)$. Dans cette formule, η représente le taux d'apprentissage (learning rate). C'est un hyperparamètre crucial qui détermine la taille du pas effectué à chaque étape : - S'il est trop grand, l'algorithme risque d'osciller et de ne jamais converger. - S'il est trop petit, la progression sera extrêmement lente. L'opération est répétée jusqu'à la convergence, c'est-à-dire lorsque le gradient devient proche de zéro (indiquant que nous avons atteint un minimum) ou lorsque le nombre maximal d'itérations est atteint.

Optimum local

La descente de gradient est une méthode permettant d'obtenir un optimum local qu'il faut distinguer de l'optimum global. En effet, l'optimum local dépend du point d'où nous décidons de partir et n'est pas forcément le meilleur optimum. Dans cette méthode, le point de départ choisi joue donc un rôle essentiel et a une influence considérable sur les paramètres estimés. Pour contrer ce problème, nous allons estimer plusieurs modèles (1000) pour chaque couple (Sex, discipline) en générant de façon aléatoire les points de départ pour chacune des estimations.

Introduction de l'aléatoire

Le point de départ choisi jouant un rôle essentiel dans la détermination des paramètres estimés, il est essentiel d'ajouter une part d'aléatoire dans le choix de ces paramètres. Ainsi nous estimerons plusieurs fois chaque modèle avec des points de départ généré aléatoirement à chaque fois. Nous allons ainsi estimer 1 000 modèles pour chaque couple afin de maximiser nos chances d'en avoir qui convergent et pouvoir ensuite choisir le plus performant.

L'aléatoire dans le modèle de Moore

3.2 Initialisation des paramètres du modèle

Afin d'estimer les paramètres du modèle de Moore, nous devons fournir à l'algorithme de descente de gradient des valeurs initiales pour a, b, c et d . Celles-ci sont générées aléatoirement à partir des propriétés observables de la série de données, selon le schéma suivant :

- a est tiré uniformément entre 0,9 et 1,2 fois la valeur de performance maximale observée, reflétant le fait que le plateau asymptotique du terme montant est légèrement supérieur au pic ;
- b est tiré uniformément autour du rapport $\frac{\text{pente initiale}}{a}$, conformément à l'approximation $f'(0) \approx ab$ valable lorsque $c \ll a$;
- c est tiré uniformément dans un voisinage étroit de $a/100$, traduisant l'hypothèse que le terme descendant est une petite perturbation devant le terme montant ;
- d est tiré uniformément autour de l'estimateur $\frac{\ln[(f(t_3)-a)/(f(t_4)-a)]}{t_3-t_4}$, obtenu par régression sur deux points situés dans la phase descendante de la courbe.

Par ailleurs, les quatre paramètres étant par définition strictement positifs, des contraintes de positivité sont imposées lors de la génération, sans restriction sur les valeurs maximales.

L'aléatoire dans le modèle IMAP

Choix du modèle le plus performant : Critère d'optimisation

Une fois les modèles estimés, il va nous falloir déterminer les paramètres optimaux pour chaque modèle afin de résumer au mieux les données et obtenir une courbe la plus représentative possible. Il nous faut donc un critère d'optimisation. Le critère d'optimisation que nous allons utiliser est assez classique : il s'agit de l'erreur quadratique (ou méthode des moindres carrés). Ce critère consiste à minimiser la somme des erreurs quadratiques, notée :

$$S(\theta) = \sum_{i=1}^N (f_i - \hat{f}(age_i, \theta))^2$$

On cherche donc :

$$\arg \min_{\theta} \sum_{i=1}^N (f_i - \hat{f}(age_i, \theta))^2$$

.

Pour chaque couple (sexe, discipline), nous allons choisir parmi les différents modèles estimés (et ayant donc convergés) celui qui MSE. On trouve ainsi les paramètres correspondant au modèle le plus performant.

Comparaison des modèles : AIC et BIC

Afin de comparer les différents modèles de régression linéaire considérés dans cette étude, les critères d'information AIC (Akaike Information Criterion) et BIC (Bayesian Information Criterion) sont utilisés. Ces deux critères reposent sur une logique commune : pénaliser la complexité du modèle afin d'éviter le surapprentissage, tout en cherchant à minimiser l'erreur de prévision sur de nouvelles observations.

AIC : Akaike Information Criterion

L'AIC est défini par

$$AIC = n \cdot \ln\left(\frac{SRC}{n}\right) + 2(p + 1)$$

où n désigne le nombre d'observations, p le nombre de variables explicatives retenues dans le modèle, et SCR la somme des carrés des résidus. Cette formule, valable sous hypothèse de normalité des erreurs, quantifie l'erreur de prévision via la divergence de Kullback-Leibler.

BIC : Bayesian Information Criterion

Le BIC est quant à lui défini par

$$BIC = n \cdot \ln\left(\frac{SRC}{n}\right) + (p + 1) \cdot \ln(n),$$

et se distingue de l'AIC uniquement par le remplacement du facteur 2 par

$$\ln(n)$$

dans le terme de pénalité. Bien que proches dans leur formulation, ces deux critères conduisent fréquemment au choix de modèles différents.

Pour chacun de ces critères, le modèle retenu est celui présentant la valeur la plus faible.

3.3 Résultats

3.4 Discussion

4 Discussion générale

Conclusion

Remerciements

Références

Voici la liste de toutes les références bibliographiques utiles à la rédaction de ce rapport :

- Allen, Sian V., et Will G. Hopkins. 2015. « Age of Peak Competitive Performance of Elite Athletes : A Systematic Review ». *Sports Medicine*.
- Carter, P. A. et al. s. d. « The age-performance relationship in the general population and strategies to delay age related decline in performance ». *Archives of Public Health*. <https://doi.org/10.1186/s13690-019-0375-8>.
- InfographicSite. 2021. « Olympians Age Distribution by Gender - Tokyo 2020 ». 2021. <https://infographicsite.com/infographic/olympians-age-distribution-by-gender/>.

Annexes




FIGURE 1 : Lancers